

SenLégal

Assistant Juridique IA spécialisé dans le
Code des Marchés Publics du Sénégal

Rapport Technique
Projet Intelligence Artificielle — Juin 2026

Encadrant : Dr KEITA

Aboubakar ABDOULAYE

Samuel AISSI

Tékiyath AMOUSSA

Leslie SAWADOGO

1. Introduction

SenLégal est une plateforme SaaS d'assistance juridique basée sur l'intelligence artificielle, spécialement conçue pour le droit de la commande publique au Sénégal. Le système utilise une architecture RAG (Retrieval-Augmented Generation) pour fournir des réponses précises et citées, ancrées sur les textes juridiques officiels.

La problématique adressée est double : d'une part, les textes juridiques sénégalais sont volumineux et complexes (Code des Marchés Publics, Recueil des Textes Juridiques 2023, décisions ARCOP/CRD). D'autre part, les modèles de langage généralistes hallucinent systématiquement sur le droit spécifique sénégalais qui n'est pas représenté dans leurs données d'entraînement.

Objectifs

- Fournir un accès instantané aux textes juridiques via langage naturel
- Garantir la traçabilité (citations article par article)
- Éliminer les hallucinations grâce à 5 couches de protection
- Proposer un modèle économique viable (freemium, paiement mobile)
- Déployer une solution complète et production-ready

2. Sources Juridiques Indexées

Le système indexe l'ensemble du corpus juridique relatif à la commande publique sénégalaise. Les documents sont traités par un pipeline d'ingestion spécialisé qui préserve la structure article par article.

Source	Contenu	Type
Décret 2022-2295	Code des Marchés Publics	Législation
Recueil Vol. 1 (2023)	Textes commande publique	Compilation
Recueil Vol. 2 (2023)	Textes complémentaires	Compilation
Décisions ARCOP/CRD	Jurisprudence (2026)	Jurisprudence

Glossaire juridique intégré

Un glossaire spécifique au droit des marchés publics sénégalais est utilisé pour l'expansion automatique des requêtes. Il couvre les acronymes suivants :

- ARCOP — Autorité de Régulation de la Commande Publique
- CRD — Comité de Règlement des Différends
- DRP — Demande de Règlement Préalable
- AOO — Appel d'Offres Ouvert
- DCE — Dossier de Consultation des Entreprises
- DRPCM — Direction de la Réglementation et des Marchés Publics
- DAO — Dossier d'Appel d'Offres

3. Architecture du Système

SenLégal adopte une architecture microservices composée de 4 services applicatifs et 3 services d'infrastructure, orchestrés via Docker Compose.

Services applicatifs

Service	Technologie	Port	Rôle
Frontend	Nuxt 4 + Vue 3 + Tailwind	3000	Interface utilisateur
Backend	NestJS 11 + Prisma 7	3001	API Gateway + logique métier
Service IA	FastAPI + Python 3.11	8001	RAG + embeddings + LLM
Caddy	Caddy Server	443	Reverse proxy + TLS

Services d'infrastructure

Service	Technologie	Port	Rôle
PostgreSQL	PostgreSQL 16	5433	Base relationnelle
ChromaDB	ChromaDB 0.5	8002	Base vectorielle
MinIO	MinIO (S3-compatible)	9000	Stockage objets

Flux de données

Le frontend communique exclusivement avec le backend NestJS via JWT. Le backend proxifie les requêtes IA vers FastAPI en utilisant un token admin. Le service IA accède à ChromaDB pour la recherche vectorielle et à Ollama Cloud pour la génération LLM. Le frontend n'a jamais accès direct au service IA.

4. Modèle d'Embedding

intfloat/multilingual-e5-small

Le modèle d'embedding choisi est multilingual-e5-small de la famille E5 (Embeddings from bidirectional Encoder representations). Ce modèle est spécifiquement optimisé pour les langues multiples dont le français, ce qui est essentiel pour un corpus juridique francophone.

Propriété	Valeur
Dimensions	384
Paramètres	~33M
Langues	100+ (français natif)
Préfixe query	query: <texte>
Préfixe passage	passage: <texte>
Métrique	Similarité cosinus
GPU requis	Non (CPU compatible)

Avantages pour le projet

- Support natif du français — crucial pour le corpus juridique
- Léger et rapide — inférence CPU en temps réel
- Préfixage asymétrique query/passage — améliore la pertinence
- Open-source — disponible sur HuggingFace sans clé API

5. Pipeline d'Ingestion

Le pipeline d'ingestion transforme les documents PDF juridiques en vecteurs interrogeables dans ChromaDB. Il est conçu pour préserver la granularité article par article des textes de loi.

Étape 1 : Parsing PDF

Utilisation de pdfplumber pour l'extraction textuelle. Normalisation des ligatures typographiques (fi, fl, ff) et réparation des césures en fin de ligne.

Étape 2 : Chunking par article

Découpage intelligent basé sur des expressions régulières détectant les en-têtes d'articles juridiques : Article 53, Art. premier, Article 7-1, etc. Les chunks dépassant 1500 caractères sont sous-découpés.

Étape 3 : Enrichissement métadonnées

Chaque chunk est annoté avec : source (nom du document), numéro d'article, et pour les décisions ARCOP : numéro de décision, date, parties impliquées.

Étape 4 : Embedding et stockage

Vectorisation par batch de 32 via multilingual-e5-small avec préfixe 'passage:'. Upsert dans ChromaDB (collection senlegal_v1) avec index HNSW cosine.

6. Pipeline de Recherche & Génération

Le pipeline de recherche est composé de 5 étapes successives qui transforment la question utilisateur en réponse citée et validée.

Étape 1 : Query Rewriting

Le LLM (Gemma 4 31B) corrige l'orthographe et la ponctuation de la requête sans en modifier le sens. Cela améliore la qualité de l'embedding.

Étape 2 : Keyword Extraction

Extraction automatique des termes juridiques clés, synonymes et acronymes via le LLM. Exemple : 'marchés publics' → 'commande publique', 'AOO', 'appel d'offres ouvert'.

Étape 3 : Multi-Query Retrieval

Deux requêtes sont envoyées à ChromaDB : la requête originale et la requête enrichie (keywords + glossaire). Les résultats sont fusionnés par meilleur score. Seuil minimum : 0.35 de similarité cosinus.

Étape 4 : Génération LLM

Le LLM reçoit un prompt strict avec les chunks récupérés comme contexte. Il doit obligatoirement citer ses sources au format [Article X — Document]. Temperature = 0.1, repeat_penalty = 1.1.

Étape 5 : Post-validation

Vérification que chaque citation [Article X — Document] existe effectivement dans le contexte récupéré. Si la validation échoue après 1 retry, un fallback déterministe (extrait brut du meilleur chunk) est renvoyé à la place.

7. Système Anti-Hallucination

Le système anti-hallucination est le coeur de la fiabilité de SenLégal. Il se compose de 5 couches de protection indépendantes et complémentaires.

Couche	Mécanisme	Action
1	Score minimum (0.35)	Refus sans appel LLM si aucun chunk pertinent
2	Prompt strict	Interdiction connaissances externes
3	Few-shot examples	Exemples in-scope vs hors-sujet
4	Post-validation	Vérif. format citations vs contexte
5	Fallback déterministe	Extrait brut si génération invalide

Paramètres LLM

- Modèle : Gemma 4 31B via Ollama Cloud
- Temperature : 0.1 (très conservateur)
- Repeat penalty : 1.1
- Streaming : SSE (Server-Sent Events)

Principe de refus

Quand le système ne trouve aucun chunk avec un score supérieur à 0.35, il refuse explicitement de répondre avec un message standardisé expliquant que la question est hors du périmètre de sa base de connaissances. Aucun appel LLM n'est effectué dans ce cas.

8. Stack Technique

Backend (TypeScript)

Technologie	Version	Rôle
NestJS	11	Framework API + injection de dépendances
Prisma	7	ORM + migrations + type safety
PostgreSQL	16	Base relationnelle principale
Passport	JWT HS256	Authentification + guards RBAC
MinIO	S3-compatible	Stockage fichiers (documents, avatars)
Bun	1.x	Runtime JavaScript rapide
Nodemailer	-	Emails transactionnels
PayDunya	SDK	Paiements mobiles XOF

Service IA (Python)

Technologie	Version	Rôle
FastAPI	0.115+	Framework web async
sentence-transformers	3.x	Embeddings E5 multilingue
ChromaDB	0.5.20	Base vectorielle HNSW
Ollama (Cloud)	-	LLM Gemma 4 31B
pdfplumber	-	Parsing PDF juridiques
Python	3.11+	Runtime

Frontend (TypeScript)

Technologie	Version	Rôle
Nuxt	4	Framework Vue full-stack SSR
Vue.js	3.5	UI réactive composants
Tailwind CSS	4	Styling utilitaire
Pinia	2	State management
VeeValidate + Zod	-	Validation formulaires
Motion-V	-	Animations

9. Modèle Économique

SenLégal utilise un modèle freemium adapté au marché ouest-africain, avec paiement mobile via PayDunya (Orange Money, Wave, carte).

Plan Gratuit (FREE)		Plan Cabinet (PRO)
Messages/jour	5	Illimité
Stockage	50 Mo	5 Go
Historique	Oui	Oui
Documents perso.	Non	Oui
Support	Standard	Prioritaire
Prix	0 FCFA	9 900 FCFA/mois

Paieiment

- Intégration PayDunya avec vérification IPN SHA-512
- Support Orange Money, Wave, cartes bancaires
- Gestion automatique expiration abonnements (cron quotidien 03h00)
- Advisory locks PostgreSQL pour idempotence des webhooks

10. Fonctionnalités

Interface utilisateur

- Inscription / connexion / récupération mot de passe
- Chat IA avec streaming SSE et citations cliquables
- Historique et gestion des conversations (titre, épingler, archiver)
- Coffre-fort documents personnels (upload/download via URLs présignées)
- Tableau de bord avec quotas en temps réel
- Gestion abonnement, factures et paiement

Interface administrateur

- Gestion utilisateurs (rôles USER/ADMIN, plans, activation)
- Upload de nouveaux PDF → ingestion asynchrone dans le RAG
- Consultation de toutes les conversations
- Logs d'erreurs serveur (HTTP $\geq$ 500)
- Backup complet (base + fichiers) et restauration
- Tableau analytique d'événements

Sécurité

- JWT HS256 + guards RBAC (USER / ADMIN)
- Throttler global : 120 req/min, plus strict sur auth/chat
- Bcrypt 12 rounds pour les mots de passe
- Token admin partagé backend ↔ service IA
- Filtrage erreurs 5xx + logging

11. Déploiement

Le projet est entièrement containerisé avec Docker et supporte 3 environnements de déploiement.

Environnement	Fichier	Particularités
Développement	docker-compose.yml	Hot-reload, Mailpit, ports exposés
Production	docker-compose.prod.yml	Build GitHub, Caddy TLS, 3 domaines
Coolify	docker-compose.coolify.yml	Variables magiques, Traefik

Containers (7 au total)

- frontend — Nuxt SSR build
- backend — NestJS + seed automatique au démarrage
- ai — FastAPI + modèle E5 pré-téléchargé dans l'image
- postgres — PostgreSQL 16 avec volumes persistants
- chromadb — ChromaDB avec persistance
- minio — Stockage S3-compatible
- caddy — Reverse proxy avec certificats TLS auto

12. Tests RAG — 100 Questions


Le système RAG a été soumis à un test exhaustif de 100 questions couvrant 10 catégories thématiques du droit de la commande publique sénégalais. Chaque question a été envoyée via l'API de streaming SSE et la réponse complète (texte, citations, scores, temps) a été collectée et analysée automatiquement.

Résultats globaux

Métrique	Valeur
Questions posées	100
Succès API	100/100 (100%)
Réponses complètes	91/100 (91%)
Réponses partielles	2/100 (2%)
Refus (hors périmètre)	7/100 (7%)
Temps médian	7.3 secondes
Temps moyen	13.1 secondes
P95	42.5 secondes
Citations par réponse	5.0 en moyenne

Qualité globale des réponses


Qualité des réponses RAG — 100 questions




Résultats par catégorie thématique

Catégorie	Répondu	Partiel	Refusé	Taux	Temps moy.
Cadre juridique génér	10	0	0	100%	18.4s
Définitions	10	0	0	100%	5.9s
Champ d'application	9	0	1	90%	15.8s
Procédures de passat	10	0	0	100%	11.6s
Garanties et exécution	9	0	1	90%	10.2s
Achats durables et PM	9	0	1	90%	7.5s
Organes (ARCOP/DO	10	0	0	100%	8.9s
PPP et concessions	8	1	1	80%	17.3s
Directives UEMOA	8	1	1	80%	24.5s
Questions transversal	8	0	2	80%	11.1s


Qualité par catégorie thématique




Distribution des temps de réponse




Scores de similarité des citations




Distribution des scores de similarité




Temps de réponse par question




Tokens générés par réponse



Sources documentaires les plus citées



Temps moyen par catégorie



Questions refusées et partielles (9/100)

Le système anti-hallucination fonctionne correctement : les refus correspondent à des informations effectivement absentes du corpus indexé. Le RAG préfère refuser plutôt qu'inventer une réponse.

Q#	Question	Statut
28	Missions diplomatiques à l'étranger	Refusé
48	Assurances du maître d'œuvre	Refusé
54	Charte de l'éthique	Refusé
73	PPP paiement public vs usagers	Partiel
76	Concession d'aménagement	Refusé
81	Code des Obligations de l'Admin.	Refusé
88	Considérations budgétaires PPP	Partiel
93	Procédure contredisant le Code	Refusé
95	Contrat de travail vs marché	Refusé

Analyse : Les catégories « Cadre juridique », « Définitions », « Procédures » et « Organes ARCOP/DCMP » obtiennent un score parfait de 100%. Les refus se concentrent sur les PPP (concepts non détaillés dans le corpus), les directives UEMOA et les questions transversales nécessitant des textes non indexés (COA, charte d'éthique, concession d'aménagement).

Tableau récapitulatif

Résumé par catégorie thématique

Catégorie	Répondu	Partiel	Refusé	Taux	Temps moy.	Tokens moy.
Cadre juridique général	10	0	0	100%	18.4s	71.1
Définitions	10	0	0	100%	5.9s	61.8
Champ d'application	9	0	1	90%	15.8s	51.9
Procédures de passation	10	0	0	100%	11.6s	65.3
Garanties et exécution	9	0	1	90%	10.2s	75.5
Achats durables et PME	9	0	1	90%	7.5s	60.6
Organes (ARCOP/DCMP)	10	0	0	100%	8.9s	63.7
PPP et concessions	8	1	1	90%	17.3s	60.3
Directives UEMOA	8	1	1	90%	24.5s	51.6
Questions transversales	8	0	2	80%	11.1s	58

13. Conclusion & Perspectives

SenLégal démontre la faisabilité d'un assistant juridique IA fiable et spécialisé, adapté au contexte ouest-africain. L'architecture RAG multi-couches, combinée à un système anti-hallucination en 5 niveaux, garantit des réponses toujours ancrées dans les textes officiels.

Les tests exhaustifs sur 100 questions couvrant l'ensemble du droit de la commande publique sénégalais confirment un taux de réponse de 91% avec zéro hallucination. Les 9 questions non répondues correspondent à des informations effectivement absentes du corpus indexé, validant ainsi le système anti-hallucination.

Le modèle économique freemium avec paiement mobile est adapté au marché cible. L'architecture microservices containerisée permet un déploiement simple et une évolutivité horizontale.

Perspectives

- Extension à d'autres domaines du droit sénégalais (OHADA, droit du travail)
- Fine-tuning d'un LLM local sur le corpus juridique francophone
- Application mobile avec support vocal (Wolof + Français)
- Partenariats institutionnels avec ARCOP et l'Ordre des Avocats
- Cross-encoder pour le re-ranking des résultats de recherche
- Indexation automatique des nouvelles décisions ARCOP (flux RSS)
- Enrichir le corpus pour couvrir les 9 questions actuellement refusées